2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 6

Galvan, Juan Bautista

Pourtau Fleischmacher, Jeronimo

Ramallo, Franco

1. Introducción

En los últimos años, las plataformas digitales de alquiler, como Airbnb, han adquirido relevancia en el sector turístico e inmobiliario, ya que permiten conectar a personas que ofrecen alojamientos con quienes buscan hospedarse por períodos cortos o prolongados. El crecimiento de este tipo de plataformas genera oportunidades económicas para los anfitriones y facilita el acceso a distintas alternativas de alojamiento. Al mismo tiempo, plantea interrogantes sobre la distribución de las propiedades, los precios, la actividad turística y los posibles efectos de los alquileres temporarios sobre el mercado de la vivienda y las comunidades locales.

Estudiar los anuncios de Airbnb en la Ciudad Autónoma de Buenos Aires permite investigar cómo se distribuyen las propiedades entre los distintos barrios, qué tipos de alojamientos predominan, cómo varían los precios y qué relación puede existir entre las características de los anuncios, su disponibilidad y las valoraciones de los huéspedes.

Para abordar esta problemática, se utiliza el conjunto de datos *Inside Airbnb Buenos Aires 2026 [1]*. Inside Airbnb es un proyecto que recopila y publica información pública del sitio de Airbnb [2] sobre anuncios de distintas ciudades del mundo. Su objetivo es proporcionar datos que permitan estudiar el impacto de los alquileres temporarios sobre las viviendas y las comunidades residenciales. La información publicada puede utilizarse para realizar análisis exploratorios, generar visualizaciones y aportar evidencia para la discusión sobre el funcionamiento de este mercado.

Cada registro representa un anuncio de alojamiento e incluye información sobre la propiedad, el anfitrión, la ubicación geográfica, la capacidad de huéspedes, el precio, la disponibilidad, la cantidad de reseñas y las puntuaciones obtenidas. Esta variedad de atributos permite abordar el problema desde diferentes perspectivas y aplicar técnicas de análisis exploratorio de datos para identificar patrones, tendencias y posibles anomalías.

Sin embargo, antes de realizar los análisis, es necesario considerar las limitaciones y la calidad de la información. Los datos representan una recopilación realizada en un período determinado y no constituyen un registro completo de todas las operaciones del mercado de alquileres temporarios. Además, la disponibilidad publicada no permite distinguir con certeza entre noches reservadas y noches bloqueadas por los anfitriones, mientras que las ubicaciones geográficas se encuentran aproximadas por motivos de privacidad [2]. Por este motivo, los resultados deben interpretarse teniendo en cuenta estas limitaciones y sin asumir que las relaciones observadas implica necesariamente causalidad.

Como parte del trabajo, se realiza una exploración inicial del conjunto de datos para conocer su estructura, los tipos de variables y la calidad de la información. También se identifican posibles

problemas, como valores faltantes o totalmente vacías, formatos inconsistentes (la columna price tiene signo y puntos), registros duplicados o valores atípicos (noches minimas de mas de 365 dias), con el propósito de evaluar su relevancia y aplicar las transformaciones necesarias antes del análisis. Las decisiones de limpieza y preparación se toman considerando las características de cada variable y los objetivos del estudio, procurando preservar la información útil y evitar conclusiones distorsionadas.

Finalmente, organizamos en secciones que presentan el conjunto de datos y su contexto, describen las tareas de exploración y preparación realizadas, desarrollan los análisis y las visualizaciones correspondientes y exponen los principales resultados obtenidos. De esta manera, se busca aplicar los conceptos y las herramientas de la ciencia de datos para comprender mejor las características de los alojamientos publicados en Airbnb en Buenos Aires y reconocer tanto las posibilidades como las limitaciones de la información disponible. En la notebook, estas tareas se corresponden con las Secciones 1 y 2 (exploración y limpieza de los datos), la Sección 3 (distribución de las variables) y la Sección 4 (validación de las hipótesis).

2. Análisis exploratorio de los datos

2.1. Origen

Los datos provienen de Inside Airbnb [1], un proyecto que compila información pública del sitio web de Airbnb [2] (Sección 1.1 del código). Se llevó a cabo un análisis exploratorio con el objetivo de comprender las principales características de la oferta de alojamientos temporarios de Airbnb en la Ciudad Autónoma de Buenos Aires e identificar patrones que permitieran formular hipótesis de interés.

2.2. Reducción de Columnas

Variables que se descartaron (Sección 1.2 del código):

- Atributos con 0 valores no nulos en el corte temporal de CABA (ej. host_response_rate, neighbourhood_group_cleansed, instant_bookable, host_acceptance_rate).
- Enlaces a perfiles/fotos, IDs de extracción y timestamps del scraper (ej. listing_url, scrape_id, picture_url, last_scraped). No aportan capacidad explicativa al modelo de negocio.
- Se descartaron las variables expresadas en meses (ej. hosts_time_as_host_months) dado que se conservó su equivalente exacto en años.
- Se eliminaron ventanas temporales cortas (ej. availability_30, number_of_reviews_l30d) en favor de las variables anualizadas (ej. availability_365, number_of_reviews_ltm).
- Se suprimieron las subcategorías de puntuación (limpieza, comunicación, ubicación) para evitar multicolinealidad, conservando únicamente el promedio general (ej. review_scores_rating).
- Se eliminó el desglose específico (ej. _entire_homes, _private_rooms), reteniendo solo el total (ej. calculated_host_listings_count).
- Descripciones narrativas o comerciales (ej. name, description, host_about) que requerirían procesamiento de lenguaje natural (NLP).
- Variables como ‘has_availability’ (casi 100% de la base comparte el mismo valor) o ‘license’ (apenas 486 datos válidos sobre 29.685), las cuales no otorgan poder discriminatorio estadístico.

2.3. Valores Atípicos y limpieza de datos

Se identificaron valores atípicos en distintas variables del conjunto de datos, principalmente en los precios, los ingresos anuales estimados y la cantidad de propiedades administradas por cada anfitrión.

Como se muestra en la Fig. 1 (Sección 3 del código), se observaron registros considerablemente superiores a los valores habituales, lo que evidencia una marcada dispersión y una asimetría positiva en sus distribuciones. Estos valores pueden influir significativamente sobre medidas como la media y la desviación estándar, por lo que se consideró necesario analizarlos antes de realizar los contrastes estadísticos y los modelos posteriores.

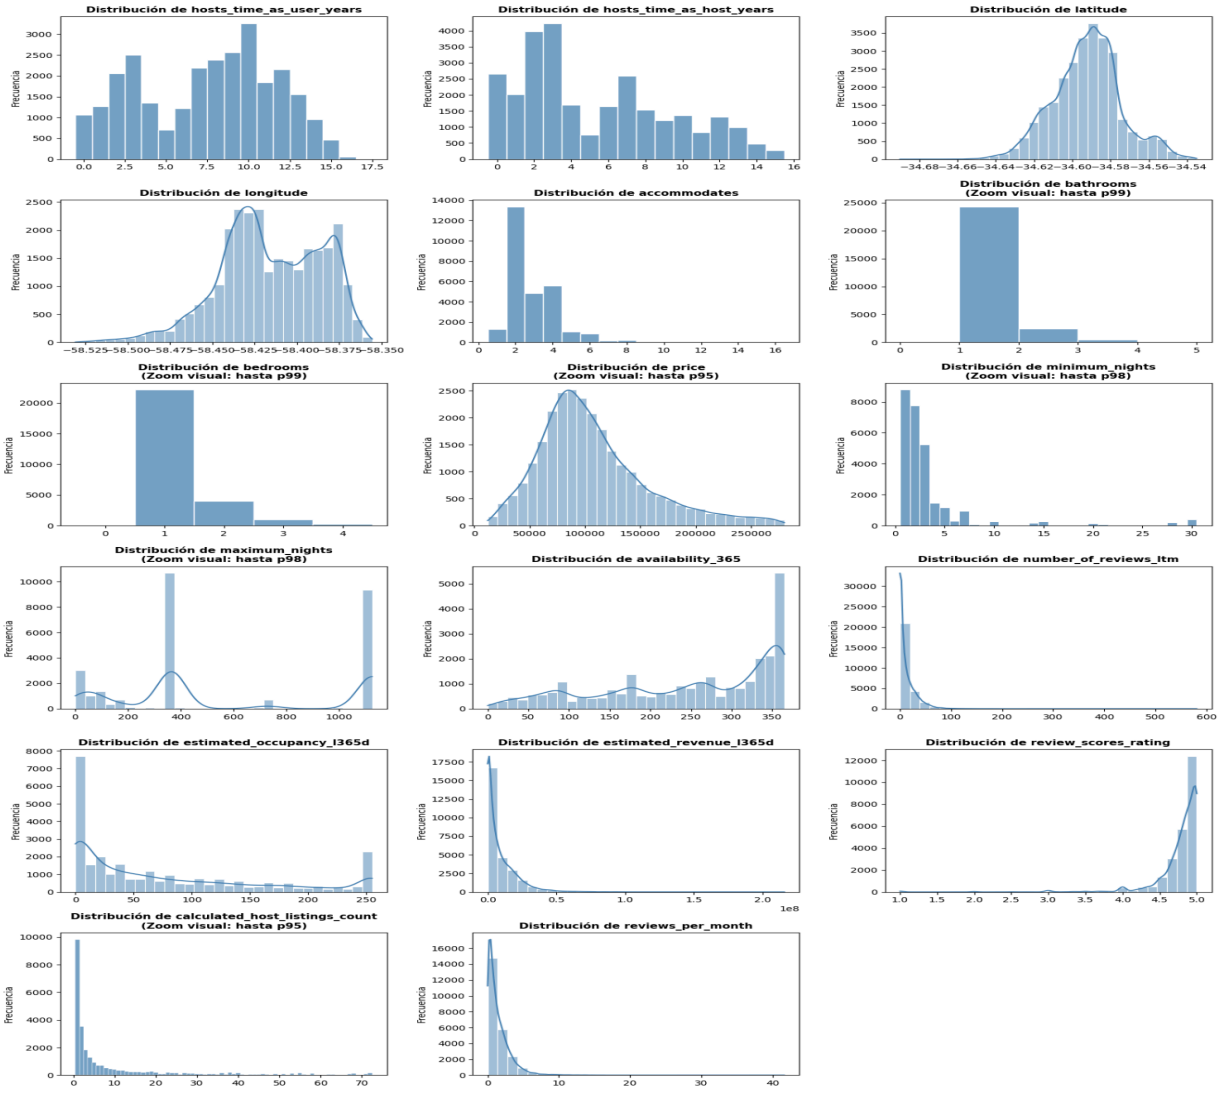


Fig. 1: Histograma para visualizar las distintas distribuciones de las variables

No se consideraron todos los valores atípicos como registros incorrectos de manera automática. Se evaluó su plausibilidad y, cuando correspondía, se aplicaron criterios de limpieza para excluir posibles errores, conservando aquellos valores elevados que resultaban razonables. Esta distinción permitió preservar la información del conjunto de datos y reducir la influencia de registros potencialmente erróneos. El tratamiento de los precios fuera de rango y de las noches máximas extremas se realiza en las Secciones 2.5.4 y 2.6 del código.

Limpieza y preparación (Sección 2 del código). Se aplicaron las siguientes acciones, cada una con su justificación:

- Precio nulo y formato (Secciones 2.5.1 y 2.5.2). Se eliminaron los 1.792 anuncios sin precio, porque es la variable objetivo e imputar introduciría sesgos en su distribución. El precio venía como texto con el signo $ y separadores de miles, y se convirtió a número.

- Otros nulos (Sección 2.5.3). Se eliminaron las filas sin 'minimum_nights', 'maximum_nights' o 'estimated_revenue_l365d': eran pocas y no hay una variable confiable para imputarlas. Junto con los anuncios sin precio, en total se descartaron 1.800 anuncios (6,1 %).

- Baños, dormitorios y camas (Sección 2.3). Tenían nulos en 'bathrooms' (11,6 %), 'bedrooms' (17,5 %) y 'beds' (8,7 %). Eliminarlos implicaba perder una parte importante de la base, y una imputación global habría atenuado la variabilidad, por lo que se imputaron con la mediana de los anuncios de igual capacidad ('accommodates'), de la que depende la cantidad de espacios.

- Comodidades (Sección 2.4). 'amenities' es un texto con muchas comodidades. Se descartaron las que están en casi toda la oferta (Wifi, aire acondicionado, cocina y TV, presentes en más del 92 % de los anuncios), porque no diferencian propiedades, y se convirtieron seis en variables binarias: heladera, ropa de cama, ascensor, cochera, balcón/patio y pileta.

- Precios irreales (Sección 2.5.4). Había precios de millones por noche y otros inverosímilmente bajos. Se eliminaron los que quedan fuera de [Q1 − 3·IQR ; Q3 + 3·IQR] calculados sobre el logaritmo del precio, es decir, fuera de $11.589 a $912.069 (294 anuncios, 1,1 %). Se usó el logaritmo porque el precio crece de forma multiplicativa; aplicar la regla al precio sin transformar eliminaba el 4,24 % de la base.

- Noches máximas (Sección 2.6.1). Se eliminaron los 11 anuncios con 'maximum_nights' mayor a 1.125 (≈ 3 años), el tope observado en los datos.

- Valores que se conservaron (Secciones 2.6.2 a 2.6.4). No se imputaron los nulos de las reseñas (son ausencias lógicas: un anuncio sin reseñas no tiene calificación), y no se eliminaron la ocupación 0 (22,3 %), el tope de 255 días (7,8 %), las reseñas altas ni las noches mínimas altas, porque son información o límites del método y no errores de carga.

Tras la limpieza quedaron 27.580 de los 29.685 anuncios originales (se descartó el 7,1 %).

2.4. Observaciones

2.4.1. Ocupación anual estimada

Una de las variables que presentó resultados más interesantes fue 'estimated_occupancy_l365d', que representa una estimación de la cantidad de días que cada alojamiento estuvo ocupado durante los últimos 365 días.

En la Fig. 2 (Sección 3 del código), se observa que su distribución presenta una marcada asimetría positiva. Se observa una gran concentración de anuncios con pocos días estimados de ocupación, junto con una cola que se extiende hacia valores superiores. La media obtenida fue de aproximadamente 74,94 días, mientras que la mediana fue de 42 días, lo que evidencia la influencia de los anuncios con niveles de ocupación más elevados.

También se identificaron dos acumulaciones particulares: una en cero días, correspondiente a anuncios sin ocupación estimada, y otra alrededor de los 255 días. Este último valor coincide con el límite superior aproximado del modelo de estimación utilizado por Inside Airbnb [2], por lo que no debe interpretarse como una medición directa de la ocupación real.

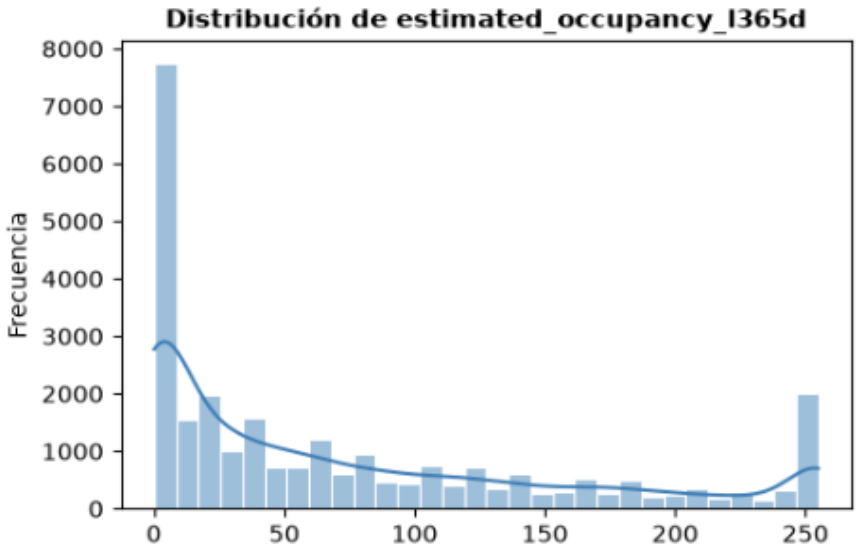


Fig. 2: Histograma para visualizar la distribución de la variable 'estimated_occupancy_l365d'

Estos resultados despertaron el interés por determinar la Hipótesis 1. De esta manera, se buscó evaluar si la oferta presenta, en términos generales, un nivel de utilización relativamente bajo.

2.4.2. Diferencias según el tipo de anfitrión

También se exploró la relación entre la condición de Superhost (host_is_superhost) y la ocupación anual estimada.

En la Fig. 3 (Sección 4, Hipótesis 2 del código), se observa que al comparar ambos grupos se observaron diferencias descriptivas importantes. Los anuncios de anfitriones estándar presentaron una mediana de ocupación de 18 días, mientras que los anuncios pertenecientes a Superhosts alcanzaron una mediana de 96 días.

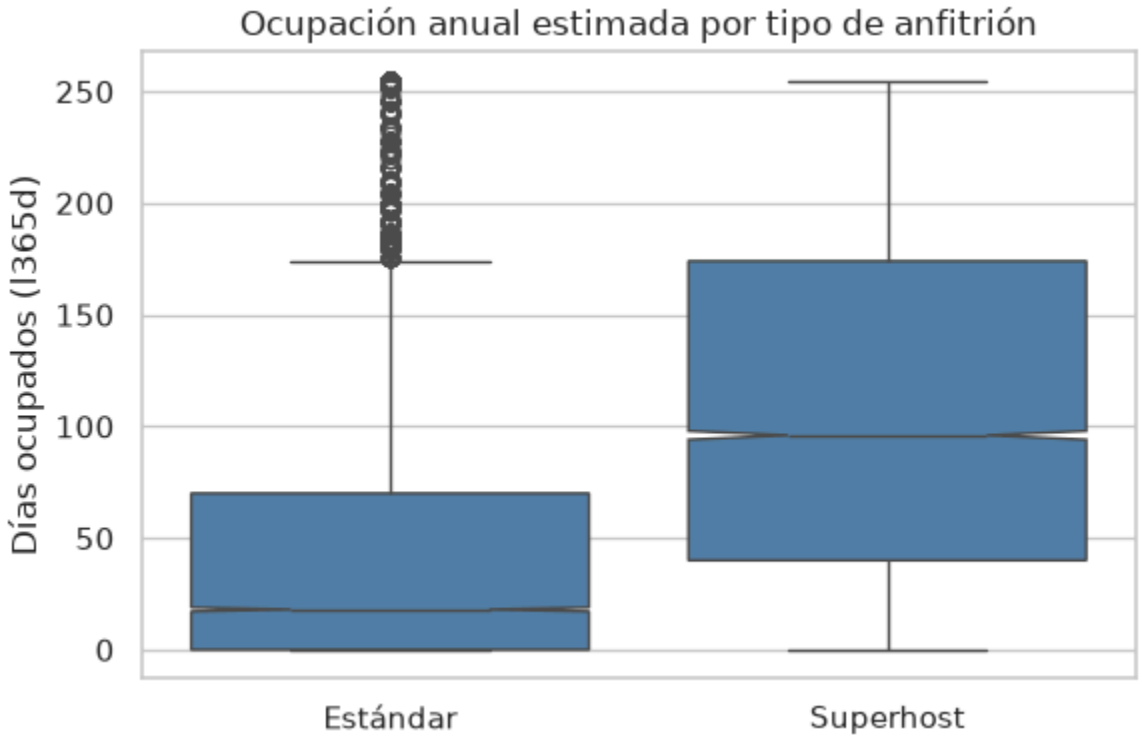


Fig. 3: Boxplot para observar la diferencia entre las distribuciones.

Esta diferencia sugirió que la condición de Superhost podría estar asociada con un mayor nivel de ocupación. A partir de esta observación surgió el análisis de la Hipótesis 2.

Sin embargo, esta relación debe interpretarse como una asociación y no necesariamente como un efecto causal, ya que también podrían intervenir otros factores, como la ubicación, la antigüedad del anuncio, el precio o la experiencia del anfitrión.

2.4.3. Relación entre ingresos, capacidad y comodidades

Se observó que los ingresos anuales estimados presentan diferencias entre los alojamientos, lo que motivó investigar qué características podrían estar asociadas con un mayor nivel de ingresos.

Se consideraron tanto características relacionadas con el anfitrión, como la condición de Superhost, como características propias de las propiedades, entre ellas la capacidad máxima y la disponibilidad de determinadas comodidades (heladera, ropa de cama, ascensor, cochera, balcón o patio y pileta).

En la Fig. 4 (Sección 4, Hipótesis 3 del código), al explorar las relaciones entre estas variables y los ingresos estimados, se identificaron asociaciones positivas de distinta intensidad. Entre ellas, se destacaron la condición de Superhost y la capacidad del alojamiento, seguidas por algunas comodidades. Asimismo, en la Fig. 5 (Sección 4, Hipótesis 3 del código), los gráficos comparativos mostraron diferencias en los niveles de ingresos entre propiedades que disponen de determinados servicios y aquellas que no los ofrecen.

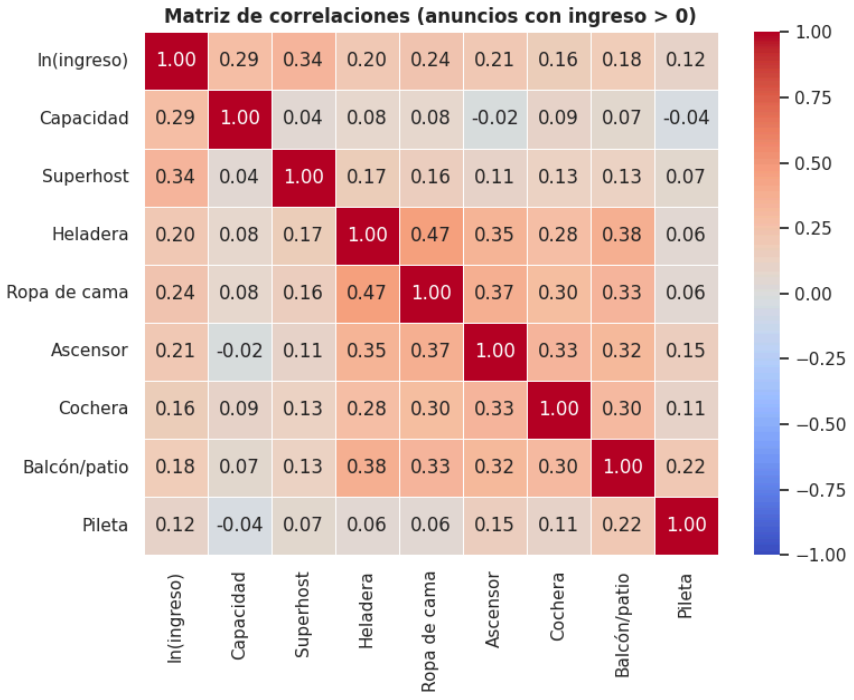


Fig. 4: Heatmap mostrando la relación entre los ingresos estimados y las variables seleccionadas.

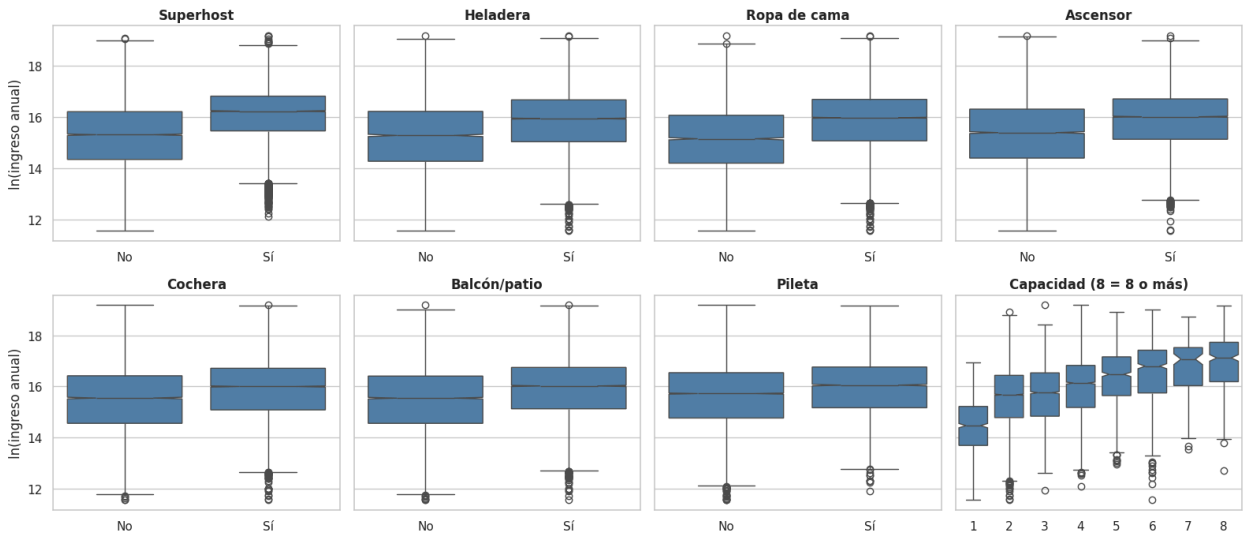


Fig. 5: Boxplot de las variables seleccionadas.

Estas observaciones motivaron la formulación de la Hipótesis 3.

3. Hipótesis y resolución

3.1. Hipótesis 1: Baja ocupación media anual de los alojamientos de Airbnb en CABA.

3.1.1. Definición de la hipótesis

La ocupación anual estimada de los anuncios de Airbnb en CABA ('estimated_occupancy_l365d') tiene una media inferior al 45 % del año, es decir, a 164,25 días ocupados de 365.

Variable: 'estimated_occupancy_l365d', cuantitativa discreta (días ocupados en los últimos 365). Es una estimación que Inside Airbnb calcula a partir de las reseñas: vale 0 para los anuncios sin reseñas en el último año y tiene un tope de 255 días (70 % del año) [2].

Justificación: se observó que la ocupación anual estimada de los alojamientos presenta una importante concentración en valores bajos. Una gran proporción de los anuncios registra niveles reducidos de ocupación. Esta observación resulta relevante desde el punto de vista económico, ya que la ocupación es uno de los principales factores que determinan los ingresos de un alojamiento temporario. Conocer su nivel promedio permite evaluar qué tan aprovechada se encuentra la oferta y establecer expectativas más realistas para quienes consideran invertir en este mercado.

3.1.2. Estrategia de abordaje

Como se muestra en la Fig. 6 (Sección 4, Hipótesis 1 del código), se analizó la distribución de la variable mediante un histograma y un gráfico Q-Q, incorporando como referencias la media, la mediana y el umbral de 164,25 días.

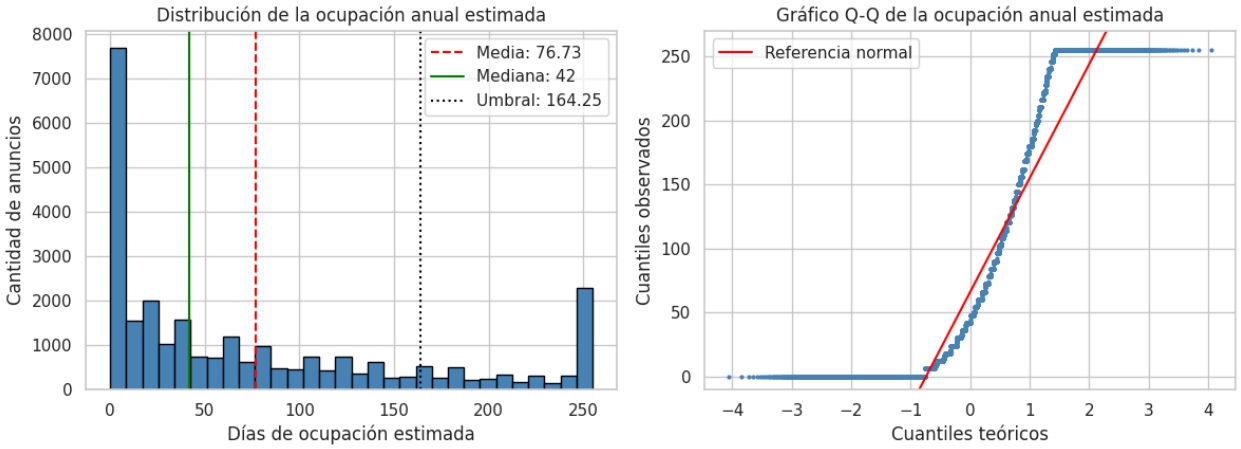


Fig. 6: Histograma y QQ-plot para analizar la distribución.

Se observó una distribución marcadamente asimétrica hacia la derecha, con una concentración importante de anuncios en cero días de ocupación y otra acumulación alrededor de los 255 días. Esta última corresponde al límite superior aproximado del modelo de estimación de Inside Airbnb.

La media (76,73 días) y la mediana (42 días) se encuentran considerablemente por debajo del umbral establecido, lo que proporciona una primera evidencia descriptiva a favor de la hipótesis.

Verificación de supuestos y selección del test

Se evaluó la **normalidad** mediante la prueba de Shapiro-Wilk, aplicada sobre una muestra aleatoria de 5.000 observaciones. Se obtuvo un estadístico (W=0,833) y un p-valor inferior a 0,001, por lo que se rechazó la hipótesis de normalidad. Este resultado coincide con lo observado en el histograma y el gráfico Q-Q.

Sin embargo, dado que el tamaño de la muestra es considerablemente grande (n=27.580), el teorema central del límite permite aproximar la distribución de la media muestral a una distribución normal, aun cuando la variable original presente asimetría. Por este motivo, se consideró adecuado utilizar un test t para una muestra.

Se planteó un contraste unilateral a izquierda, con un nivel de significancia de 0,05:

$H_0 : \mu \geq 164.25\ dias$

$H_1 : \mu < 164.25\ dias$

Donde μ representa la media poblacional de días de ocupación anual estimada.

Consideración sobre la independencia de las observaciones

Se identificó que algunos anfitriones administran múltiples alojamientos, por lo que las observaciones pertenecientes a un mismo anfitrión podrían no ser completamente independientes.

Para evaluar si esta característica modifica la conclusión, se repitió el contraste utilizando un único anuncio seleccionado aleatoriamente por cada anfitrión. De esta manera, se redujo la posible influencia de la dependencia entre anuncios administrados por una misma persona.

3.1.3. Resultados obtenidos y discusión

En la Tabla 1 (Sección 4, Hipótesis 1 del código), al realizar las pruebas se obtuvieron los siguientes resultados:

Versión	Por qué se hizo	n	Media (días)	t	Resultado
Todos los anuncios	Análisis principal	27.580	76,7	−175,1	Se rechaza H_0
Solo anuncios activos (con reseñas en el último año)	El 22,3 % de los anuncios tiene ocupación 0 y podría estar bajando el promedio	21.424	98,8	−117,2	Se rechaza H_0
Un anuncio por anfitrión	Los anuncios de un mismo anfitrión no son independientes	13.517	74,5	−127,1	Se rechaza H_0

Tabla 1: Resultados de las pruebas.

Decisión: en las tres versiones el p-valor es menor que α = 0,05 ($p < 0,001$), por lo que se rechaza H_0.

Conclusión: se confirma la hipótesis, la ocupación anual media estimada de los anuncios de Airbnb en CABA es inferior al 45 % del año. La media es de 76,7 días, menos de la mitad del umbral, y todo el intervalo de confianza del 95 % queda por debajo de 164,25. De hecho, H0 se rechazaría con cualquier umbral mayor a ~78 días (≃ 21 % del año), por lo que la conclusión no depende de haber elegido el 45 %. El resultado se mantiene también sin los anuncios inactivos (n = 21.424): la media sube a 98,8 días (27,1 % del año), pero sigue muy por debajo del umbral (t = −117,2).

Implicancia: al evaluar una inversión en Airbnb en CABA conviene usar estimaciones conservadoras de ocupación y no asumir que los alojamientos permanecerán ocupados gran parte del año. Como referencia, el anuncio típico tiene 42 días (mediana) y el anuncio activo promedio, unos 99.

Limitación: la ocupación es una estimación con un tope de 255 días. Aun si todos los anuncios que están en ese tope hubieran estado ocupados los 365 días, la media subiría a unos 85 días y seguiría muy por debajo del umbral.

3.2. Hipótesis 2: Confianza del Superhost

3.2.1. Definición de la hipótesis

Los anuncios de anfitriones con la insignia "Superhost" (`host_is_superhost`) tienen una mediana de ocupación anual estimada (`estimated_occupancy_l365d`) significativamente superior a la de los anuncios de anfitriones estándar.

Variables:

- **Independiente (agrupación):** 'host_is_superhost'`, cualitativa nominal dicotómica. Es una característica del anfitrión: todos sus anuncios comparten el mismo valor.
- **Dependiente (respuesta)**: 'estimated_occupancy_l365d', cuantitativa discreta (días ocupados en los últimos 365). Es una característica de cada anuncio.

Justificación: Airbnb evalúa cada tres meses si el anfitrión cumple cuatro criterios: calificación promedio de al menos 4,8, tasa de respuesta de al menos 90 %, menos de 1 % de cancelaciones y al menos 10 estadías en el último año (o 100 noches en al menos 3 estadías) [3]. Validar esta hipótesis permite cuantificar si ese esfuerzo operativo se asocia con mayor ocupación. Si los Superhosts ocupan significativamente más, podría justificarse que un inversor destine esfuerzo a la calidad del servicio para alcanzar la insignia, entendiéndolo como una inversión en marketing y no como un gasto.

3.2.2. Estrategia de abordaje

Como se muestra en la Fig. 7 (Sección 4, Hipótesis 2 del código), se analizó la variable 'estimated_occupancy_l365d', diferenciando entre alquiler Estandar y Superhost. Permite observar la diferencia entre las distribuciones. Junto con la Tabla 2, se puede observar los distintos valores entre ambos tipos de anfitrión.

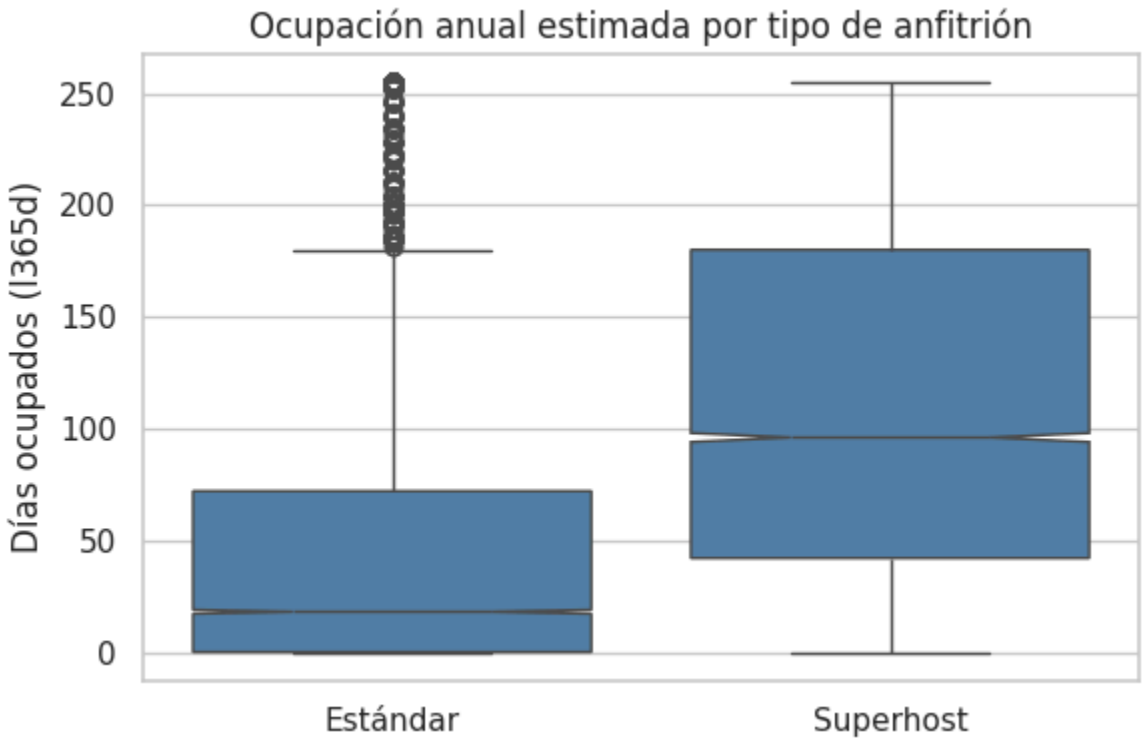


Fig. 7: Boxplot de ocupación anual estimada por tipo de anfitrión.

grupo	count	median	mean
Estandar	16007	18.0	50.467421
Superhost	11573	96.0	113.054610
Spearman	0.420	p-valor	0

Tabla 2: Análisis descriptivo.

La mediana de los Superhost (96 días) es más de cinco veces la de los anuncios estándar (18 días). El gráfico de cajas (con *notches*) muestra una diferencia marcada entre ambos grupos:

- **Estándar**: distribución comprimida hacia valores bajos. El 75 % de los anuncios no supera los 73 días ocupados.
- **Superhost**: caja más alta (mayor dispersión) y desplazada hacia arriba, con el 50 % central entre 43 y 180 días.
- **Muescas**: no se superponen, lo que sugiere que las medianas poblacionales difieren. La del grupo Estándar es más angosta por su mayor tamaño muestral y su menor rango intercuartílico.
- **Valores atípicos**: el grupo Estándar tiene una cola densa de atípicos hasta 255 días, es decir, una ocupación alta es atípica dentro de ese grupo. En los Superhosts el bigote llega a ese mismo valor sin marcar atípicos.
- **Asociación**: Spearman $\rho = 0.420$ ($p < 0.001$) entre ser Superhost (codificado 0/1) y la ocupación: asociación positiva moderada.

Verificación de supuestos y selección del test

Se evaluó la **normalidad** utilizando un QQ-plot, como se muestra en Fig. 8, y la prueba de Shapiro-Wilk (sobre una submuestra aleatoria de 5.000 anuncios por grupo)

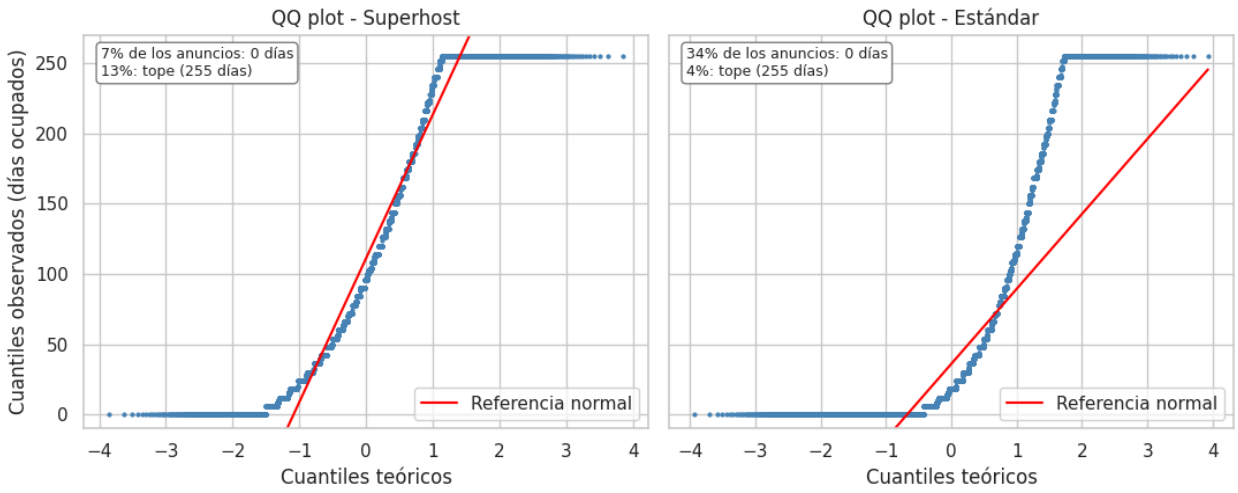


Fig. 8: QQ-plot para los tipos de anfitrión.

Superhost W = 0,911 y Estándar W = 0,723, ambos con p < 0,001. Se **rechaza la normalidad** en los dos grupos. Los QQ-plots lo confirman: los puntos se apartan de la recta de referencia y forman dos tramos horizontales, uno en 0 días (7 % de los Superhosts y 34 % de los Estándar) y otro en el tope de 255 días del modelo de estimación (13 % y 4 %, respectivamente). La variable está inflada en cero y con un tope en el extremo superior.

Al evaluar **homocedasticidad,** se utilizó el test de Levene, centrado en la mediana. Como resultado, el estadístico es igual a 1296,2, p < 0,001. Se **rechaza la igualdad de varianzas**.

Independencia: no se cumple. La insignia es una característica del anfitrión, por lo que todos los anuncios de un mismo anfitrión pertenecen al mismo grupo y comparten gestión. Los anuncios no son independientes y el test tiende a sobreestimar la significancia. Se verifica repitiendo el contraste con un solo anuncio por anfitrión.

En base a los supuesto, la hipótesis se formuló sobre medianas, y con una distribución inflada en cero y con tope la media describe mal al anuncio típico; se opta por la **prueba de la mediana**, que no supone normalidad ni varianzas iguales y contrasta directamente lo que afirma la hipótesis: las medianas.

$$H_0 : \theta_{Superhost} = \theta_{Estandar}$$

$$H_1 : \theta_{Superhost} > \theta_{Estandar}$$

Donde θ es la mediana poblacional de ocupación anual de cada grupo.

3.2.3. Resultados obtenidos y discusión

Como se muestra en la Tabla 3 (Sección 4, Hipótesis 2 del código), se repitió el contraste para comprobar que el resultado no dependa de decisiones del análisis.

Versión	Por qué se hizo	n (Superhost / Estándar)	Mediana (días)	% sobre la mediana global	χ^2	Resultado
Todos los anuncios	Análisis principal	11.573 / 16.007	96 vs 18	72,3 % vs 33,6 %	4.023,0	Se rechaza H_0
Un anuncio por anfitrión	La insignia es del anfitrión y sus anuncios no son independientes	5.159 / 8.358	114 vs 12	80,6 % vs 29,5 %	3.327,0	Se rechaza H_0
Solo anuncios activos (con reseñas en el último año)	Los Superhosts casi no tienen ocupación 0 (7 % contra 34 % de los Estándar)	10.799 / 10.625	108 vs 48	62,1 % vs 35,8 %	1.480,7	Se rechaza H_0

Tabla 3: Resultado al repetir el contraste.

Decisión: con α = 0,05 se rechaza H0 en las tres versiones ($p < 0,001$).

Conclusión: se confirma la hipótesis en su parte medible: el estatus de Superhost se asocia con una mediana de ocupación anual estimada significativamente superior. Con todos los anuncios, la mediana de los Superhost (96 días) supera en 78 días a la de los anfitriones estándar (18 días), y el 72,3 % de los Superhost queda por encima de la mediana global, contra el 33,6 % de los Estándar. La diferencia se mantiene con un anuncio por anfitrión, que deja observaciones independientes entre sí. Sin los anuncios inactivos la brecha se reduce, pero los Superhost siguen ocupando más del doble (108 contra 48 días).

Implicancia: alcanzar la insignia mediante una mejor atención al cliente es una estrategia promisoria para un inversor, pero no un retorno garantizado.

Limitaciones: Es una asociación y no causalidad: no puede afirmarse que la insignia genere la ventaja ni que se traduzca en más reservas. Los Superhost pueden diferir también en antigüedad, ubicación o precio. La relación es en parte inversa: para obtener la insignia se exige un mínimo de estadías, por lo que los anuncios sin actividad casi nunca la tienen.

La ocupación se estima a partir de las reseñas, por lo que incluso entre anuncios activos la diferencia puede reflejar más reseñas y no necesariamente más reservas. Los anuncios de un mismo anfitrión comparten grupo y no son estrictamente independientes. Por eso se hizo la verificación con un anuncio por anfitrión, que da el mismo resultado.

3.3. Hipótesis 3: Ingreso anual, Superhost y servicios a igual capacidad

3.3.1. Definición de la hipótesis

Manteniendo constante la capacidad del alojamiento, el estatus de Superhost y los servicios que ofrece (heladera, ropa de cama, ascensor, cochera, balcón/patio y pileta) se asocian con un mayor ingreso anual estimado.

Variables: -

Dependiente: 'estimated_revenue_l365d', cuantitativa continua (se modela su logaritmo, por su fuerte asimetría). -

Control (igual capacidad): 'accommodates', cuantitativa discreta, tratada como categórica (un valor por cada capacidad). -

Independientes de interés: 'host_is_superhost' (Superhost, factor de gestión) y 'has_refrigerator', 'has_bed_linens', 'has_elevator', 'has_parking', 'has_balcony_patio', 'has_pool'. Todas son cualitativas dicotómicas.

Justificación: permite ordenar los factores por su aporte al ingreso a igual capacidad, por ejemplo cuánto se asocia la insignia Superhost frente a una cochera o una pileta, y orienta dónde conviene invertir al anfitrión o a la agencia. La Hipótesis 2 mostró que los Superhost tienen mayor ocupación; acá se evalúa si eso se traduce en ingreso al descontar capacidad y equipamiento. Cochera y ascensor facilitan el uso en una ciudad de edificios en altura y poco estacionamiento; pileta y balcón/patio son diferenciales de gama alta; heladera y ropa de cama son servicios básicos que reducen la fricción del huésped. Como el ingreso es una estimación de Inside Airbnb basada en su modelo de ocupación [2], y no un ingreso observado, cada efecto combina tarifa y demanda.

3.3.2. Estrategia de abordaje

Se utilizó una regresión lineal múltiple, porque permite estimar el efecto de cada factor manteniendo constantes los demás, incluida la capacidad, y contrastar cada efecto con un test t sobre su coeficiente.

El modelo es: $\ln(\text{ingreso}_i) = \beta 0 + \gamma_{\text{capacidad}(i)} + \beta 2 \cdot \text{superhost}_i + \beta 3 \cdot \text{heladera}_i + \beta 4 \cdot \text{ropa}_i + \beta 5 \cdot \text{ascensor}_i + \beta 6 \cdot \text{cochera}_i + \beta 7 \cdot \text{balcón}_i + \beta 8 \cdot \text{pileta}_i + \varepsilon_i$

donde γ toma un valor distinto para cada capacidad (1, 2, 3, ... huéspedes), de modo que cada coeficiente compara alojamientos con la misma capacidad.

Base de análisis: anuncios con ingreso mayor a 0 (n = 21.424 de 27.580). Los 6.156 restantes (22,3 %) no tienen ingreso estimado, porque no recibieron reseñas en el último año, y ln(0) no existe. Por lo tanto, la conclusión se refiere a anuncios con actividad.

Se planteó un contraste unilateral para cada factor, con nivel de significancia α = 0,05: H0: βj ≤ 0 vs. H1: βj > 0, para j = 2, ..., 8 (superhost, heladera, ropa de cama, ascensor, cochera, balcón/patio y pileta). Como contraste conjunto complementario se usó el test F sobre los siete coeficientes: H0: β2 = β3 = ... = β8 = 0 vs. H1: al menos uno distinto de 0.

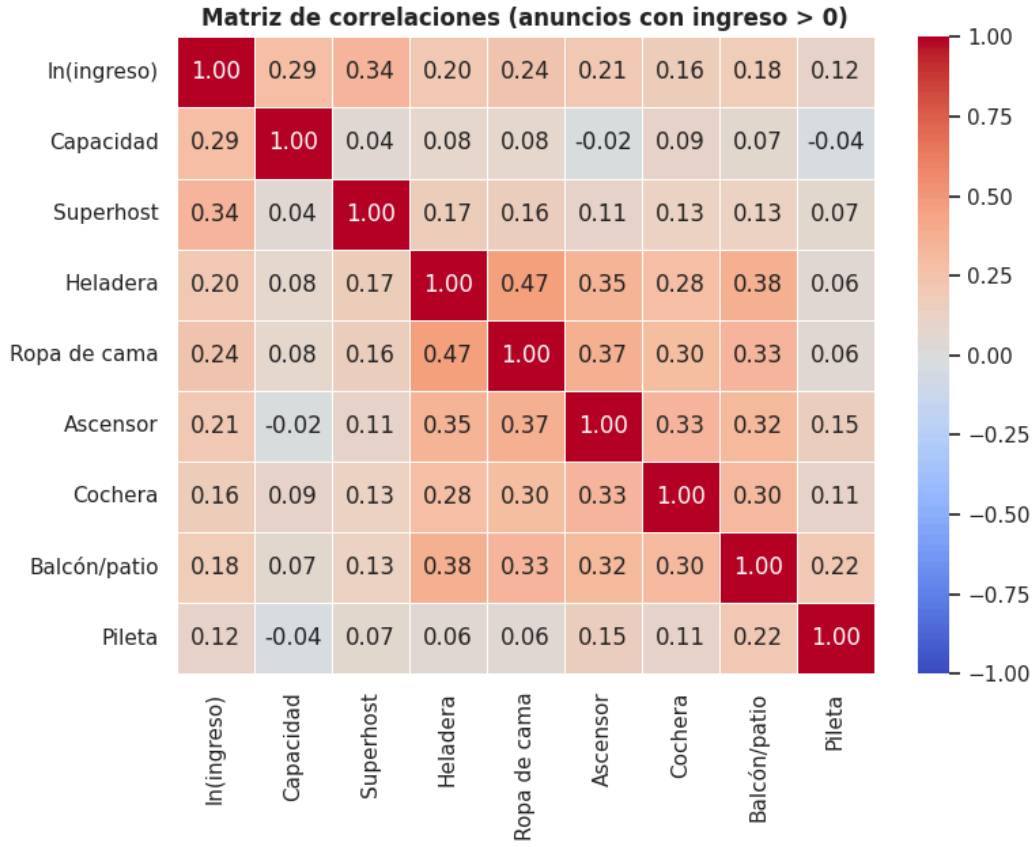


Fig. 9: Matriz de correlación entre ingreso y las variables.

Exploración previa. La Fig. 9 (Sección 4, Hipótesis 3 del código) muestra las correlaciones entre ln(ingreso) y las variables del modelo. Todas son positivas, de intensidad baja a moderada: la más alta es la de Superhost (r = 0,34), seguida por la capacidad (0,29) y por las comodidades (0,12 a 0,24). Entre las variables explicativas la relación es débil o moderada (máximo 0,47, entre heladera y ropa de cama), por lo que no se anticipa multicolinealidad grave.

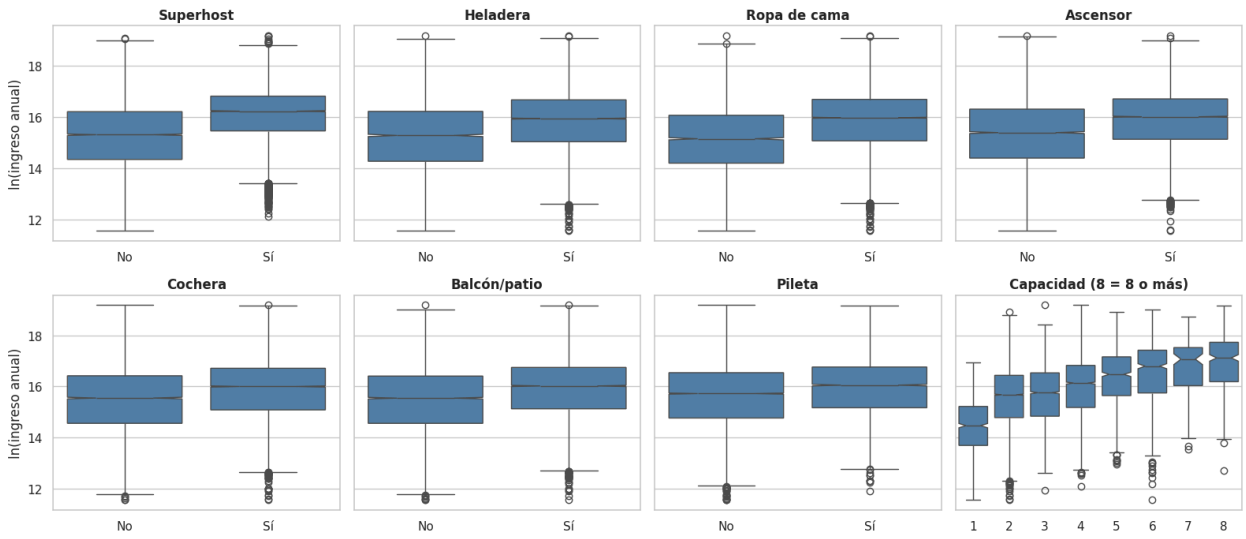


Fig. 10: Boxplot por factor.

La Fig. 10 compara la distribución de ln(ingreso) según cada factor: en los siete la mediana es mayor en el grupo "Sí" que en el "No", con la mayor diferencia en Superhost. Las cajas se solapan bastante, lo que indica mucha dispersión no explicada por estas variables. Estas asociaciones son bivariadas: la regresión permite separar el aporte de cada factor manteniendo los demás constantes.

Verificación de supuestos y selección del test

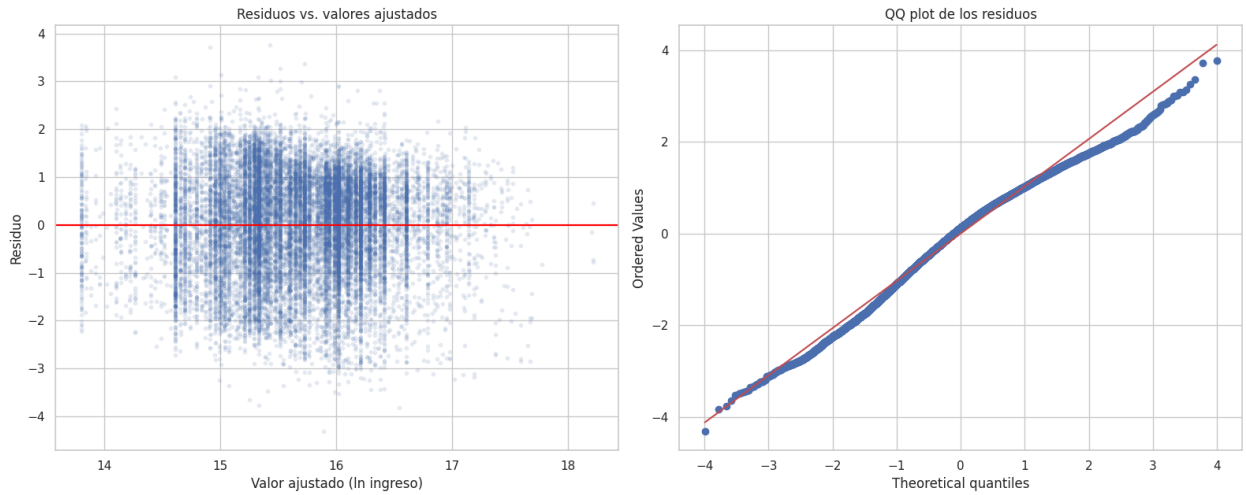


Fig. 11: Gráfico de Residuos y QQ-plot de los residuos. Linealidad y Normalidad.

La Fig. 11 muestra los residuos contra los valores ajustados y el gráfico Q-Q de los residuos. Los resultados fueron: -

Linealidad: se cumple en lo esencial. Los residuos se distribuyen alrededor de 0 sin una curvatura marcada.

Normalidad: se cumple solo de forma aproximada. Shapiro-Wilk rechaza ($W = 0{,}986$; $p < 0{,}001$), pero W está muy cerca de 1 y el gráfico Q-Q sigue la recta en el centro, apartándose en los extremos. Con n = 21.424 la falta de normalidad no es crítica, porque por el teorema central del límite los coeficientes estimados son aproximadamente normales.

Independencia: no se cumple. El estadístico de Durbin-Watson vale 1,75 con el orden original y 1,57 al ordenar por 'host_id', ambos menores que 2, lo que indica que los errores de anuncios de un mismo anfitrión están correlacionados).

Homocedasticidad: no se cumple. Breusch-Pagan rechaza ($p < 0{,}001$) y la dispersión de los residuos es menor en los valores ajustados más altos.

Multicolinealidad: se cumple. Los factores de inflación de la varianza (VIF) de los siete factores van de 1,05 a 1,45, muy por debajo de 5.

La falta de independencia y de homocedasticidad no sesga los coeficientes estimados, pero puede volver imprecisos sus errores estándar y p-valores. Para evaluar si la dependencia entre anuncios de un mismo anfitrión modifica la conclusión, se repitió la regresión con un único anuncio por anfitrión, elegido al azar (n = 10.651).

3.3.3. Resultados obtenidos y discusión

El modelo con todos los anuncios explica el 25,8 % de la variabilidad del logaritmo del ingreso (R^2 ajustado = 0,257), y el de un anuncio por anfitrión el 30,9 % (R^2 ajustado = 0,309). El test F conjunto rechaza H0 en ambas versiones, es decir, los siete factores en conjunto aportan información sobre el ingreso. En la Tabla 4 (Sección 4, Hipótesis 3 del código) se muestra el efecto de cada factor, expresado en porcentaje del ingreso a igual capacidad.

Factor	Efecto % (todos / uno por anfitrión)	p unilateral (todos / uno por anfitrión)	Decisión (α = 0,05)
Superhost	+99,8 % / +150,8 %	< 0,001 / < 0,001	Se rechaza H0
Ropa de cama	+35,0 % / +22,4 %	< 0,001 / < 0,001	Se rechaza H0
Ascensor	+29,1 % / +20,7 %	< 0,001 / < 0,001	Se rechaza H0
Pileta	+20,4 % / +19,4 %	< 0,001 / < 0,001	Se rechaza H0
Balcón/patio	+8,4 % / +6,0 %	< 0,001 / 0,004	Se rechaza H0
Heladera	+4,5 % / +8,5 %	0,017 / 0,002	Se rechaza H0
Cochera	+3,7 % / +4,5 %	0,012 / 0,022	Se rechaza H0

Tabla 4: Comparación con todos los anuncios vs uno por anfitrión.

Se confirma la hipótesis: a igual capacidad, los anuncios con Superhost, heladera, ropa de cama, ascensor, cochera, balcón/patio y pileta tienen un ingreso anual estimado mayor que los que no los tienen.

Por magnitud, el factor más asociado al ingreso es ser Superhost (aproximadamente +100 % a +151 %). Le siguen la ropa de cama, el ascensor y la pileta (entre +19 % y +35 %). Balcón/patio, heladera y cochera tienen asociaciones chicas (entre +4 % y +8,5 %).

Implicancia: para un anfitrión o una agencia, la gestión que lleva a ser Superhost es la palanca más asociada al ingreso, por encima de cualquier servicio. Entre los servicios, la ropa de cama, el ascensor y la pileta son los que más se asocian, mientras que heladera, cochera y balcón/patio aportan poco.

Limitaciones: - Es una asociación y no causalidad: por ejemplo, ser Superhost refleja buena gestión y reseñas, y no necesariamente causa por sí solo más ingreso. - Las magnitudes cambian entre versiones (por ejemplo, Superhost: +100 % contra +151 %), aunque no el signo ni la decisión. Por eso se informa el rango. -

Por la heterocedasticidad, los errores estándar y los p-valores pueden ser algo imprecisos, y son siete contrastes simultáneos. Heladera y cochera tienen la evidencia más débil (efecto chico, p entre 0,002 y 0,022 e intervalo inferior cercano a 0), por lo que esas dos conclusiones deben leerse con más cautela.

3.4. Hipótesis 4: Concentración de la oferta en multipropietarios

3.4.1. Definición de la hipótesis

Más del 60 % de los anuncios de Airbnb en CABA pertenecen a anfitriones con más de una propiedad publicada (multipropiedad), y no a personas que alquilan su propio hogar.

Variable: 'calculated_host_listings_count', cuantitativa discreta (cantidad de anuncios del anfitrión en la ciudad). Es una característica del anfitrión: todos sus anuncios heredan el mismo valor. Se transforma en una variable dicotómica que vale 1 si el anuncio es de un multipropietario (valor ≥ 2) y 0 en caso contrario; su media es la proporción de anuncios de multipropietarios.

Justificación: Airbnb se presenta como una plataforma donde las personas comparten su hogar, pero en los grandes destinos turísticos existe una profesionalización de la oferta, con administradoras y propietarios con varias unidades. Si la proporción de anuncios de multipropietarios es alta, el competidor típico de un anfitrión o inversor no es un particular con su propio hogar, sino un operador profesional.

Sensibilidad: Como "multipropiedad" no equivale a "agencia", se repite el contraste exigiendo 3, 5 y 10 o más anuncios.

3.4.2. Estrategia de abordaje

Como se muestra en la Fig. 12 (Sección 4, Hipótesis 4 del código), se analizó la distribución de la cantidad de anuncios por anfitrión mediante un gráfico de barras por tramos, junto con la proporción de la oferta según el criterio de multipropiedad.

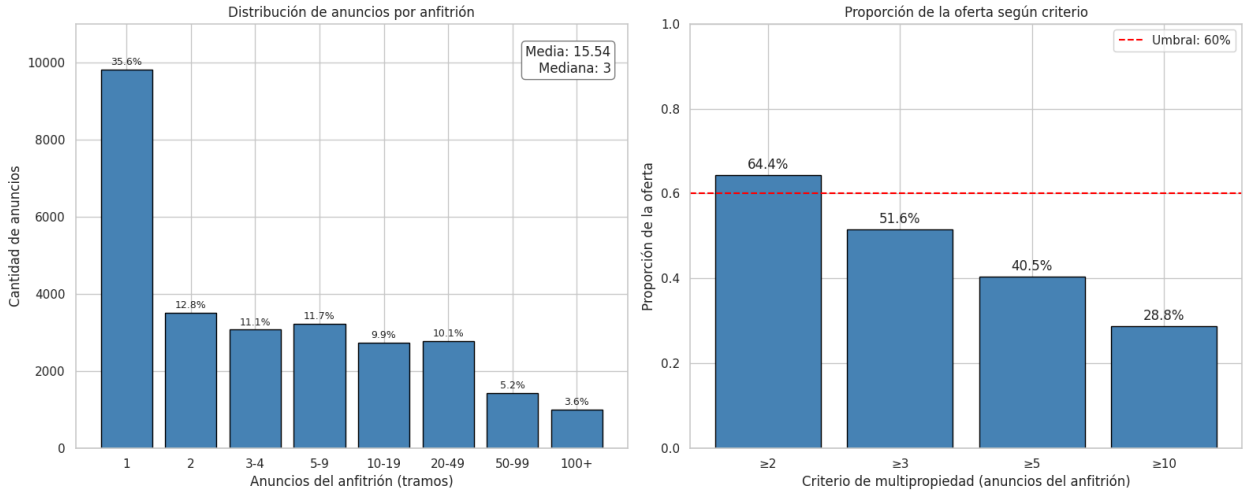


Fig. 12: Distribución de los anuncios según el tamaño del anfitrión (izquierda) y proporción de la oferta según el criterio de multipropiedad (derecha).

Verificación de supuestos y selección del test

-Normalidad: la variable es dicotómica (0/1), por lo que no corresponde evaluar la normalidad de los datos. Lo relevante es la distribución de la media muestral, que por el teorema central del límite es aproximadamente normal porque la muestra es muy grande (n = 27.580). Por eso se utiliza el test t para una muestra.

-Independencia: no se cumple. El valor de la variable pertenece al anfitrión, así que los anuncios de un mismo anfitrión comparten el valor. A diferencia de las hipótesis 1 y 2, no sirve repetir el contraste con un solo anuncio por anfitrión: eso mediría la proporción de anfitriones y no la de anuncios, que es otra cantidad. Esta dependencia se informa como limitación.

Se planteó un contraste unilateral a derecha, con un nivel de significancia de 0,05: $H_0 : \mu \leq 0{,}60$ $H_1 : \mu > 0{,}60$ donde μ es la media poblacional de la variable dicotómica, es decir, la proporción de anuncios de multipropietarios. Se rechaza H_0 si $t > 1{,}645$ (valor crítico para $\alpha = 0{,}05$ unilateral).

3.4.3. Resultados obtenidos y discusión

Con el criterio principal (2 o más anuncios por anfitrión), el 64,4 % de los anuncios pertenece a multipropietarios (error estándar = 0,0029). El estadístico es t = 15,10, mayor al valor crítico de 1,645 ($p < 0,001$), y el intervalo de confianza del 95 % es (63,8 % ; 64,9 %). En la Tabla 5 (Sección 4, Hipótesis 4 del código) se muestra, además, cómo cambia el resultado según cuántos anuncios se exija para considerar a un anfitrión multipropietario.

Criterio	$\hat{p}$	t	Decisión
≥ 2 anuncios	64,4 %	15,10	se rechaza H_0
≥ 3 anuncios	51,6 %	−27,93	no se rechaza H_0
≥ 5 anuncios	40,5 %	−66,13	no se rechaza H_0
≥ 10 anuncios	28,8 %	−114,56	no se rechaza H_0

Tabla 5: Sensibilidad del resultado al criterio de multipropiedad.

Decisión: Con el criterio principal, t = 15,10 supera el valor crítico de 1,645, por lo que se rechaza H_0.

Con 3, 5 y 10 o más anuncios el estadístico es negativo, porque la proporción queda por debajo del 60 %, y no se rechaza H_0.

Conclusión: se confirma la hipótesis con el criterio del enunciado (2 o más anuncios por anfitrión). El 64,4 % de los anuncios pertenece a multipropietarios y todo el intervalo de confianza queda por encima del 60 %. Sin embargo, la diferencia con el umbral es de 4,4 puntos porcentuales, por lo que la conclusión no es holgada y depende de cuántos anuncios se exija para considerar a un anfitrión como agencia: con 3 o más la proporción baja a 51,6 %, con 5 o más a 40,5 % y con 10 o más a 28,8 %. Medido por anfitriones y no por anuncios, solo el 27,3 % tiene 2 o más anuncios, pero ese grupo concentra el 64,4 % de la oferta: pocos anfitriones controlan gran parte de los anuncios.

Implicancia: para un anfitrión o inversor, una parte importante de la competencia son operadores con varias propiedades: casi 3 de cada 10 anuncios (28,8 %) pertenecen a anfitriones con 10 o más. Aun así, con criterios más exigentes de agencia la mayoría de la oferta no queda en sus manos.

Limitaciones: Tener 2 o más anuncios es solo una aproximación a "operador profesional": una persona con una segunda propiedad cuenta como multipropietaria.

Los anuncios de un mismo anfitrión no son independientes, por lo que el t y el intervalo de confianza son más optimistas de lo real. Conviene leer el resultado por la distancia entre 64,4 % y 60 % y no por la magnitud de t.

3.5. Hipótesis 5: Más del doble de precio del alquiler

3.5.1. Definición de la hipótesis

Alquilar un espacio entero cuesta, en promedio, más del doble que alquilar una habitación privada.

Variables:

- **Independiente**: 'room_type', cualitativa nominal. Se comparan sólo dos categorías: 'Entire home/apt' (espacio entero) y 'Private room' (habitación privada). Se excluyen 'Shared room' y 'Hotel room'.
- **Dependiente**: 'price', cuantitativa continua.

Justificación: El tipo de alojamiento (propiedad completa o habitación dentro de una vivienda) es uno de los factores que más se asocia al precio en el mercado de alquileres temporales. Esta hipótesis evalúa si esa brecha es tan grande que el precio medio de un espacio entero supera el doble del de una habitación privada. Para un anfitrión que decide cómo ofrecer su propiedad, o para la plataforma al definir precios de referencia, dimensionar esa brecha ayuda a valorar lo que aporta el espacio completo. La diferencia refleja privacidad, pero también mayor capacidad y equipamiento, por lo que se interpreta como asociación y no como efecto causal.

3.5.2. Estrategia de abordaje

Como se muestra en la Fig. 13 (Sección 4, Hipótesis 5 del código), el promedio queda por encima de la mediana en ambos grupos, lo que indica asimetría a la derecha (algunos precios altos suben el promedio). El efecto es más fuerte en las habitaciones privadas.

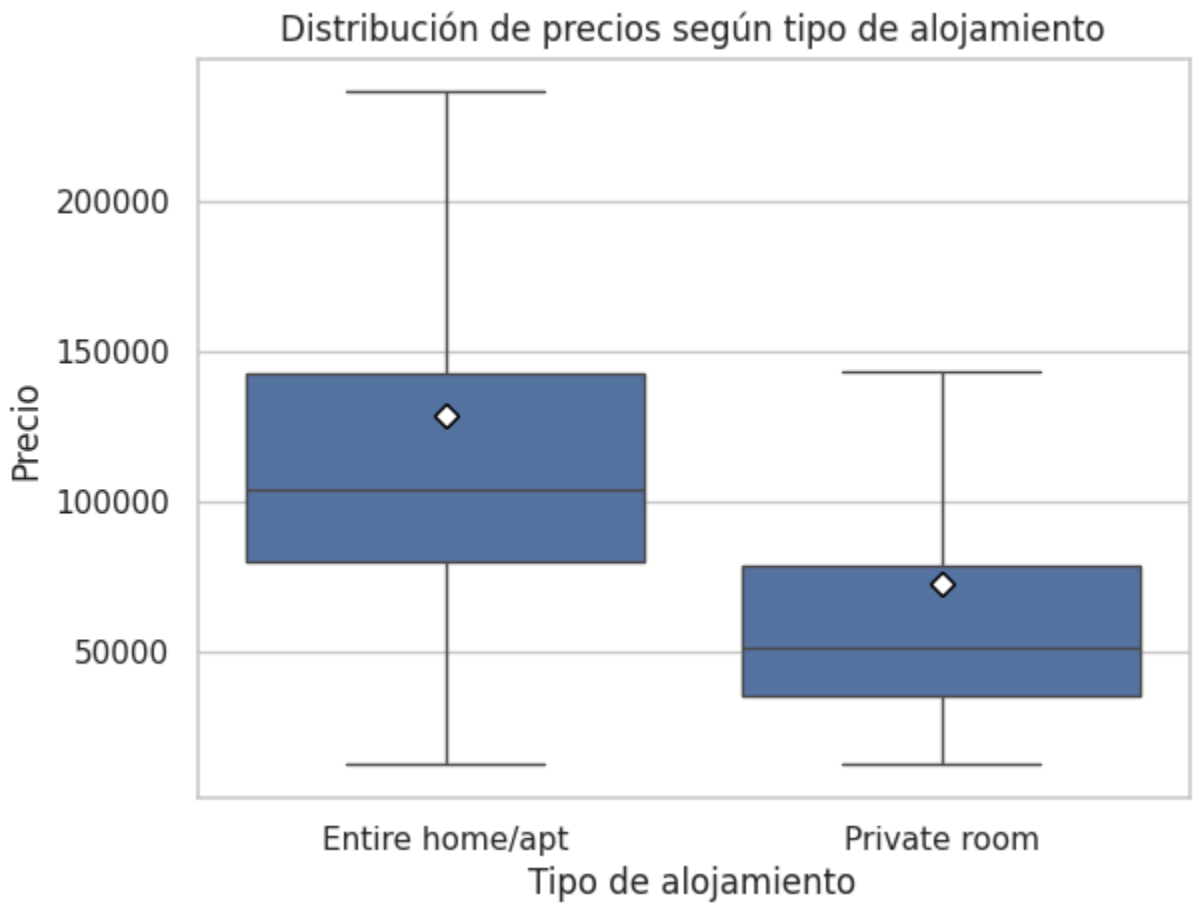


Fig. 13: Boxplot que muestra la distribución del tipo Entire y Private en cuanto al precio. El boxplot se muestra sin valores atípicos, para que las cajas se vean bien. El rombo marca el promedio de cada grupo.

- **Los espacios enteros son más caros**: la mitad central de sus precios va de ≃ 80.000 a ≃ 143.000, con mediana ≃ 104.000. En las habitaciones privadas va de ≃ 35.000 a ≃ 79.000, con mediana ≃ 51.000.
- **Casi no hay superposición**: el 75 % de las habitaciones privadas cuesta menos de ≃ 78.600, y el 75 % de los espacios enteros cuesta más de ≃ 80.100.

Verificación de supuestos y selección del test

Para evaluar **normalidad** se utilizó un gráfico QQ-plot y el test de Shapiro-Wilk. Como se muestra en la Fig. 14, los QQ-plots muestran una cola derecha muy pesada en ambos grupos: los precios más altos son varias veces mayores a lo esperado bajo normalidad. Shapiro-Wilk lo confirma ($W = 0{,}644$ en espacios enteros y $W = 0{,}514$ en habitaciones privadas, $p < 0{,}001$ en ambos).

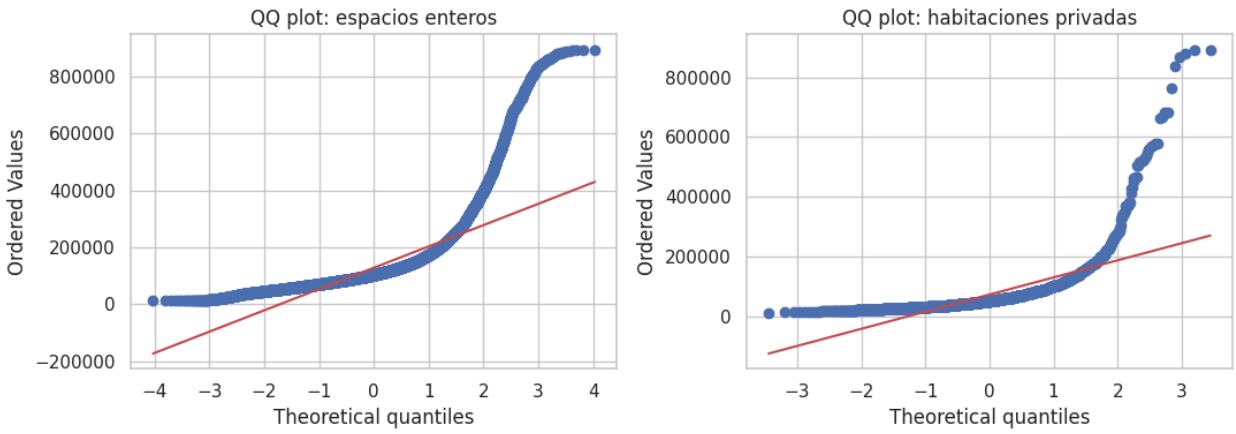


Fig. 14: QQ-plots que muestra la distribución del tipo Entire y Private en cuanto al precio.

Independencia: no se cumple, porque los anuncios de un mismo anfitrión se parecen entre sí y algunos anfitriones ofrecen ambos tipos de alojamiento. Se verifica repitiendo el test con un solo anuncio por anfitrión.

Homocedasticidad: no se cumple. Levene rechaza la igualdad de varianzas ($p < 0{,}001$), con desvíos de ≈ 91.700 en espacios enteros y ≈ 80.000 en habitaciones privadas.

- La falta de normalidad no es crítica porque el contraste es sobre promedios y las muestras son grandes (24.870 y 2.446 anuncios). Por el teorema central del límite, el promedio es aproximadamente normal aunque los precios no lo sean.
- Las varianzas distintas no son un problema porque el t de Welch no supone varianzas iguales.
- La dependencia entre anuncios de un mismo anfitrión se evalúa repitiendo el test con un solo anuncio por anfitrión, donde los anuncios sí son independientes.

Se aplica el t de Welch unilateral sobre 'price' sin transformar, comparando el promedio de los espacios enteros con el doble del de las habitaciones privadas.

$$H_0 : \mu_{Entero} \leq 2\,\mu_{Privado}$$

$$H_1 : \mu_{Entero} > 2\,\mu_{Privado}$$

3.5.3. Resultados obtenidos y discusión

En la Tabla 6 (Sección 4, Hipótesis 5 del código), se puede ver los resultados del test, en cual en ambas versiones (todos los anuncios y un anuncio por anfitrión) el p-valor unilateral es ≈ 1, mayor que $\alpha = 0{,}05$, por lo que **no se rechaza H_0.**

Versión	n entero	n privada	Prom. entero	Prom. privada	Razón	t de Welch	p unilateral
Todos los anuncios	24.870	2.446	128.381	72.603	1,77	−5,12	1,0000
Un anuncio por anfitrión	12.404	1.084	117.366	70.894	1,66	−4,71	1,0000

Tabla 6: Resultados del test en ambas versiones.

Conclusión: los datos no respaldan el enunciado. El precio promedio de un espacio entero no llega al doble del de una habitación privada: en promedio cuesta entre 1,66 y 1,77 veces más (es decir, entre 66 % y 77 % más), según la versión.

El estadístico t es negativo en ambos casos, lo que significa que el promedio observado de los espacios enteros queda por debajo del doble del de las habitaciones privadas, y no por encima. Tampoco cambia al eliminar la dependencia entre anuncios de un mismo anfitrión.

Implicancia: para dimensionar la brecha entre ofrecer una propiedad entera o una habitación, conviene usar un factor cercano a 1,7 sobre el promedio y no un factor de 2.

Limitaciones: Es una asociación y no causalidad: los espacios enteros también tienen mayor capacidad y equipamiento, no solo privacidad. Con un anuncio por anfitrión se usan menos anuncios y cada anfitrión pesa lo mismo, por eso la razón baja de 1,77 a 1,66. La conclusión es la misma.

3.6. Hipótesis 6: Independencia y precio a igual capacidad

3.6.1. Definición de la hipótesis

A igual capacidad de huéspedes, un alojamiento se alquila más caro si garantiza mayor independencia: una cama para cada persona (no compartir colchón), mayor cantidad de baños por huésped y reserva automática.

Variables

- **Dependiente**: ‘price’, cuantitativa continua (se modela su logaritmo).
- **Control (igual capacidad):** ‘accommodates’, cuantitativa discreta, tratada como categórica (un valor por cada capacidad).
- **Independientes de interés:**
    - ‘cama_propia’: vale 1 si ‘beds’ ≥ ‘accommodates’ (hay al menos una cama por huésped) y 0 en caso contrario. Cualitativa dicotómica.
    - ‘banos_por_huesped’: ‘bathrooms’ / ‘accommodates’. Cuantitativa continua.
    - ‘instant_bookable’ (reserva automática): cualitativa dicotómica. No se puede evaluar porque la columna no tiene datos.

Justificación: Para un anfitrión, saber si ofrecer más independencia (una cama por persona, más baños por huésped) se traduce en un precio más alto ayuda a decidir si vale la pena invertir en ello. Se compara a igual capacidad para no confundir independencia con tamaño: un alojamiento para 8 personas es más caro que uno para 2 por tener más lugar, no por ser más independiente.

3.6.2. Estrategia de abordaje

Se utilizó una regresión lineal múltiple, porque permite estimar el efecto de cada variable manteniendo constantes las demás, que es lo que significa "a igual capacidad", y contrastar cada efecto con un test t sobre su coeficiente.

El modelo es: $\ln(\text{precio}_i) = \beta_0 + \gamma_{\text{capacidad}(i)} + \beta_2 \cdot \text{cama}_i + \beta_3 \cdot \text{baños}_i + \varepsilon_i$

donde γ toma un valor distinto para cada capacidad (1, 2, 3, … 16 huéspedes), de modo que cada coeficiente compara alojamientos con la misma capacidad.

Preparación de las variables. Se calcularon las camas y los baños por huésped dividiendo ‘beds’ y ‘bathrooms’ por la capacidad. Algunos anuncios tienen valores imposibles (hasta 25 camas o 20 baños por huésped), que se interpretaron como errores de carga: se descartaron los que superan 2 camas o 2 baños por huésped, es decir, 293 anuncios (1,1 %), y quedaron 27.287. La variable ‘cama_propia’ vale 1 para el 17,5 % de los anuncios.

Su reparto según la capacidad muestra que los alojamientos para 1 huésped siempre tienen cama propia (no aportan información sobre su efecto), que entre 2 y 6 huéspedes (94 % de los anuncios) hay casos de ambos tipos en cantidad suficiente, y que los de 7 o más huéspedes (2,2 %) tienen muy pocos casos con cama propia. Por eso la capacidad se controla por categorías.

Se planteó un contraste unilateral para cada variable, con nivel de significancia $\alpha = 0{,}05$:

Cama para cada persona: $H_0: \beta_2 \leq 0$ vs. $H_1: \beta_2 > 0$ Más baños por huésped: $H_0: \beta_3 \leq 0$ vs. $H_1: \beta_3 > 0$.

Exploración previa. La Fig. 15 (Sección 4, Hipótesis 6 del código) compara el precio para alojamientos de 2, 3 y 4 huéspedes, es decir, entre alojamientos de la misma capacidad.

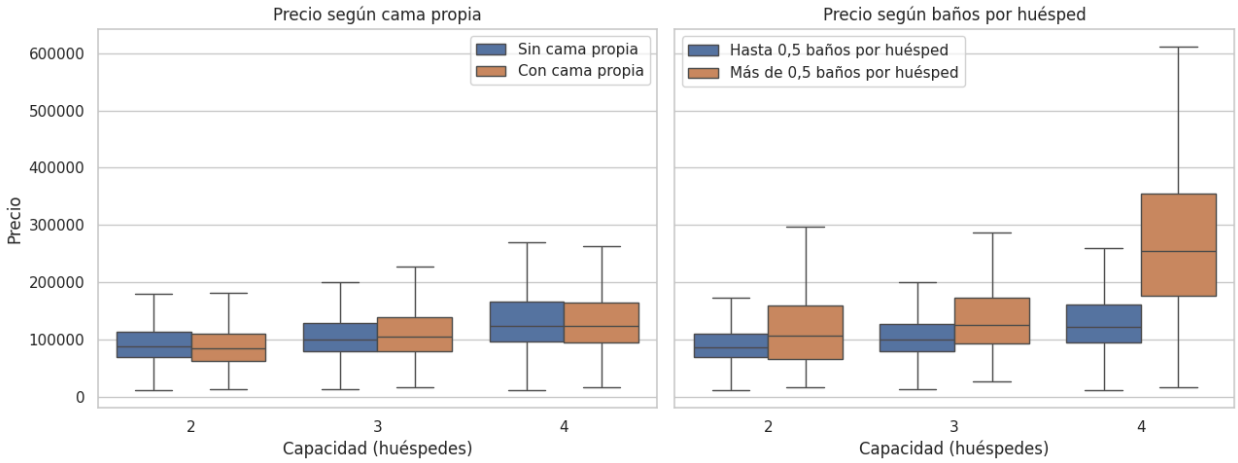


Fig. 15: Boxplots del precio según cama propia (izquierda) y según baños por huésped (derecha), para alojamientos de 2, 3 y 4 huéspedes.

Para la cama propia no se ve una diferencia consistente: con 2 huéspedes la mediana es menor con cama propia ($84.678 contra 89435), con 3 es algo mayor (104.952 contra 100.760) y con 4 prácticamente no cambia (124.688 contra $123.752). Para los baños, en las tres capacidades los alojamientos con más de 0,5 baños por huésped tienen precios más altos: la mediana sube 22 % con 2 huéspedes y 26 % con 3. Con 4 huéspedes se duplica, aunque ese grupo tiene solo 169 anuncios y mucha dispersión.

Verificación de supuestos

La Fig. 16 muestra los residuos contra los valores ajustados y el gráfico Q-Q de los residuos. Los resultados fueron:

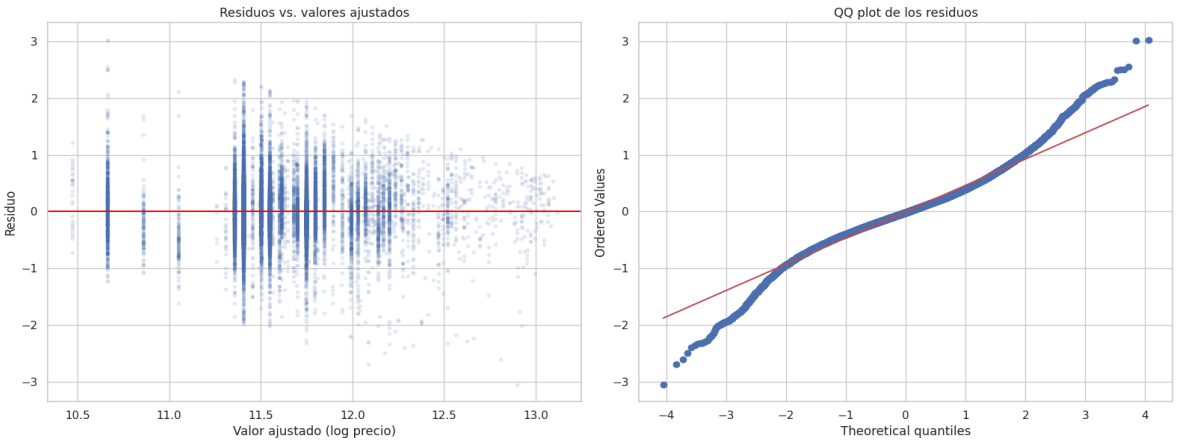


Fig. 16: Residuos contra valores ajustados (izquierda) y gráfico Q-Q de los residuos (derecha) del modelo de regresión.

- Linealidad: se cumple en lo esencial. Los residuos se distribuyen alrededor de 0 sin una curvatura marcada.

- Normalidad: se cumple solo de forma aproximada. Shapiro-Wilk rechaza ($W = 0{,}973$; $p < 0{,}001$), pero W está cerca de 1 y el gráfico Q-Q sigue la recta en el centro, con colas algo más pesadas. Con n = 27.287 la falta de normalidad no es crítica.

- Independencia: no se cumple. El estadístico de Durbin-Watson vale 1,60 con el orden original y 1,37 al ordenar por 'host_id', ambos menores que 2, lo que indica que los errores de anuncios de un mismo anfitrión están correlacionados ($\approx 0{,}3$).

- Homocedasticidad: no se cumple. Breusch-Pagan rechaza ($p < 0{,}001$) y la dispersión de los residuos es menor en los valores ajustados más altos.

- Multicolinealidad: se cumple. Los VIF son 1,26 para 'cama_propia' y 2,59 para 'banos_por_huesped', muy por debajo de 5.

La falta de independencia y de homocedasticidad no sesga los coeficientes estimados, pero puede volver imprecisos sus errores estándar y p-valores. Para evaluar si la dependencia entre anuncios de un mismo anfitrión modifica la conclusión, se repitió la regresión con un único anuncio por anfitrión, elegido al azar (n = 13.488).

3.6.3. Resultados obtenidos y discusión

El modelo con todos los anuncios (n = 27.287) explica el 30,5 % de la variabilidad del logaritmo del precio (R^2 ajustado = 0,304). En la Tabla 7 (Sección 4, Hipótesis 6 del código) se muestra el efecto de cada variable, con todos los anuncios y con un anuncio por anfitrión. Para los baños se toma un aumento de 0,5 baños por huésped, por ejemplo un alojamiento para 2 con 2 baños en lugar de 1.

Variable	Efecto % (todos / uno por anfitrión)	IC 95 % del efecto (todos / uno por anfitrión)	p unilateral (todos / uno por anfitrión)	Decisión (α = 0,05)
Cama propia	−4,9 % / −2,8 %	(−6,4 ; −3,3) / (−5,0 ; −0,6)	≈ 1 / 0,994	No se rechaza H0
Baños por huésped (+0,5)	+21,4 % / +33,3 %	(19,0 ; 23,9) / (29,4 ; 37,3)	< 0,001 / < 0,001	Se rechaza H0

Tabla 7: Efecto de cada variable sobre el precio (a igual capacidad), intervalo de confianza, p-valor unilateral y decisión, con todos los anuncios (n = 27.287) y con un anuncio por anfitrión (n = 13.488).

Decisión: para los baños por huésped se rechaza H0 en ambas versiones. Para la cama propia no se rechaza H0.

Conclusión: la hipótesis se confirma solo en parte. La parte de los baños se confirma: a igual capacidad, tener más baños por huésped se asocia con un precio mayor, y la conclusión es la misma con todos los anuncios y con uno por anfitrión.

La parte de la cama propia no se confirma: el p unilateral es ≈ 1, así que no hay evidencia de que garantizar una cama por persona encarezca el alquiler. Además, el coeficiente es negativo y su intervalo excluye el 0, es decir, hay una asociación negativa chica (entre −6 % y −1 %). La reserva automática no pudo evaluarse por falta de datos.

Implicancia: para un anfitrión, aumentar los baños en relación con la capacidad es la forma de independencia que más se asocia con un precio mayor. En cambio, ofrecer una cama por huésped no se asocia con mayor precio.

Limitaciones: Es una asociación y no causalidad: los alojamientos con más baños por huésped pueden ser también de mayor categoría. La magnitud del efecto de los baños cambia entre versiones (+21 % contra +33 %), aunque no el signo ni la decisión. Por eso se informa el rango. - ‘cama_propia’ compara camas con huéspedes: una cama doble cuenta como una sola, por lo que no mide exactamente "no compartir colchón". -

‘beds’ y ‘bathrooms’ tenían nulos (≈ 9 % y 12 %) imputados con la mediana por capacidad, lo que debilita el contraste de ambas variables. -

La heterocedasticidad y la dependencia entre anuncios del mismo anfitrión pueden volver imprecisos los errores estándar y los p-valores. La verificación con un anuncio por anfitrión da la misma conclusión.

4. Conclusiones

A partir del análisis de los alojamientos de Airbnb en la Ciudad Autónoma de Buenos Aires se observó una oferta muy heterogénea: la ocupación estimada es baja en la mayoría de los anuncios y una parte importante de la oferta está en manos de anfitriones con varias propiedades. Los resultados de las seis hipótesis fueron:

- Hipótesis 1 (ocupación): se confirmó. La ocupación media anual estimada es de 76,7 días (21 % del año), muy inferior al 45 %.

- Hipótesis 2 (Superhost y ocupación): se confirmó. La mediana de ocupación de los anuncios de Superhost (96 días) es mayor que la de los anfitriones estándar (18 días).

- Hipótesis 3 (ingreso): se confirmó. A igual capacidad, el estatus Superhost y los seis servicios analizados (heladera, ropa de cama, ascensor, cochera, balcón/patio y pileta) se asocian con un mayor ingreso estimado. El Superhost es el factor más asociado y heladera y cochera tienen la evidencia más débil.

- Hipótesis 4 (multipropietarios): se confirmó con el criterio de 2 o más propiedades (64,4 % de los anuncios), pero no con criterios más estrictos (51,6 % con 3 o más y 28,8 % con 10 o más).

- Hipótesis 5 (espacio entero contra habitación privada): no se confirmó. El precio promedio de un espacio entero es entre 1,66 y 1,77 veces el de una habitación privada, menos del doble.

- Hipótesis 6 (independencia y precio): se confirmó solo en parte. A igual capacidad, más baños por huésped se asocia con un precio mayor, como era de esperar, pero tener una cama por persona no: incluso se asocia con un precio algo menor (entre −3 % y −5 %), por lo que los datos no respaldan que más independencia implique siempre un precio más alto. La reserva automática no pudo evaluarse por falta de datos.

En conjunto, para quien evalúa invertir en este mercado, conviene proyectar ocupaciones conservadoras, y la gestión que lleva a ser Superhost y algunos servicios se asocian con mayores ingresos. No obstante, la ocupación y los ingresos son estimaciones, los análisis muestran asociaciones y no relaciones de causalidad, y los anuncios de un mismo anfitrión no son independientes entre sí. Por eso, en las hipótesis donde fue posible, se verificó el resultado con un anuncio por anfitrión, y las conclusiones se mantuvieron.

Referencias

[1] Inside Airbnb. Get the Data (Buenos Aires, Ciudad Autónoma de Buenos Aires, Argentina; listings.csv.gz, datos del 23 de septiembre de 2026). https://insideairbnb.com/get-the-data/

[2] Inside Airbnb. Data Assumptions. https://insideairbnb.com/data-assumptions/

[3] Airbnb. Superhost: criterios de evaluación. https://www.airbnb.com/d/superhost